Modul 3
Implementasi dan Perbandingan Metode Clustering (K-Means, K-Median, DBSCAN, Mean Shift, dan Fuzzy C-Means) Pada Dataset Kesehatan Ibu Hamil

Cantika Latifatul Nur Ella (24031554023), Sofia Dwi Kinasih (24031554079)
Kelas 2024A
Dosen Pengampu Mata Kuliah: Dinda Galuh Guminta, M.Stat.

Abstrak.
Kesehatan ibu hamil merupakan indikator penting pembangunan kesehatan nasional sebuah negara. Penelitian ini membandingkan lima metode *clustering*, yaitu *K-Means, K-Medians, DBSCAN, Mean Shift*, dan *Fuzzy C-Means,* untuk mengelompokkan pola risiko kesehatan ibu hamil berdasarkan dataset *Maternal Health Risk Assessment* yang memuat 1.205 observasi dan 11 variabel klinis. Evaluasi performa menggunakan *Silhouette Index* menunjukkan bahwa *Fuzzy C-Means* dengan dua cluster optimal menghasilkan nilai terbaik sebesar 0,459, di mana cluster pertama merepresentasikan kelompok ibu hamil berisiko tinggi dan cluster kedua merepresentasikan kelompok berisiko rendah berdasarkan indikator seperti kadar gula darah, tekanan darah, dan BMI.
Kata kunci: Kesehatan ibu hamil, *Clustering, Fuzzy C-Means, Silhuoette Index*

BAB 1 Pendahuluan

Kesehatan ibu selama kehamilan merupakan salah satu indikator utama keberhasilan pembangunan kesehatan suatu negara, karena berpengaruh langsung terhadap kesehatan bayi dan perkembangan masyarakat secara keseluruhan (Ishak, 2024). World Health Organization (WHO) menegaskan bahwa komplikasi selama kehamilan dan persalinan masih menjadi penyebab utama morbiditas dan mortalitas ibu di negara berkembang, dengan rata-rata 808 wanita kehilangan nyawa setiap hari pada tahun 2017 (Max dan Hannah, 2024). Di Indonesia, risiko kesehatan selama kehamilan seperti anemia, hipertensi gestasional, preeklampsia, diabetes gestasional, serta infeksi masih menjadi masalah serius. Berdasarkan data Sensus Penduduk 2020, angka kematian ibu (AKI) mencapai 189 per 100.000 kelahiran hidup dan angka kematian bayi (AKB) mencapai 16,85 per 1.000 kelahiran hidup, menempatkan Indonesia pada peringkat kedua di ASEAN dalam kasus kematian ibu (Tarmizi, 2023). Kondisi ini tidak hanya berdampak pada keselamatan ibu, tetapi juga pada kesehatan janin, risiko kelahiran prematur, dan berat badan lahir rendah.

Permasalahan tersebut mendorong perlunya analisis data yang mampu mengidentifikasi pola risiko kesehatan ibu hamil secara sistematis. Data yang bersifat numerik, multivariat, dan kompleks membuat statistik deskriptif kurang memadai, sehingga teknik clustering dalam data mining menjadi pendekatan yang tepat untuk mengelompokkan ibu hamil berdasarkan kemiripan karakteristik dan mengungkap pola tersembunyi yang dapat mendukung pengambilan keputusan kesehatan.

Penelitian ini menerapkan dan membandingkan lima metode clustering. K-Means merupakan algoritma yang paling umum digunakan karena sederhana dan efisien, bekerja dengan mengelompokkan data berdasarkan jarak terhadap centroid (Maulindar & Yudha, 2023). K-Medians merupakan pengembangan K-Means yang menggunakan median sebagai pusat klaster sehingga lebih tahan terhadap outlier, menghasilkan estimasi centroid yang lebih stabil pada data dengan nilai ekstrem (Chen et al., 2023). DBSCAN adalah algoritma berbasis kepadatan yang tidak memerlukan penentuan jumlah klaster di awal dan mampu mengidentifikasi noise, terbukti efektif mengenali kelompok pasien yang bermakna secara klinis dari data rekam medis (Chicco et al., 2025). Mean Shift bekerja dengan menggeser titik data menuju area berkepadatan tertinggi secara adaptif tanpa asumsi jumlah klaster tertentu, dengan akurasi yang lebih baik pada dataset berukuran kecil meskipun membutuhkan waktu komputasi lebih lama (Cariou et al., 2022. Fuzzy C-Means (FCM) memungkinkan setiap data memiliki derajat keanggotaan di lebih dari satu klaster, sehingga cocok untuk data kesehatan ibu hamil yang batas risikonya tidak selalu tegas (Setiawan et al., 2023). Untuk membandingkan performa kelima metode tersebut secara objektif, diperlukan ukuran evaluasi yang tidak memerlukan label data sebenarnya. *Silhouette Index* merupakan salah satu metode evaluasi *clustering unsupervised* yang mengukur seberapa baik suatu data berada dalam clusternya sendiri dibandingkan *cluster* lain, dengan nilai berkisar antara -1 hingga 1, di mana nilai yang lebih tinggi menunjukkan

kualitas *clustering* yang lebih baik (Shutaywi & Kachouie, 2021).

Berdasarkan permasalahan yang telah diuraikan, pola risiko kesehatan ibu hamil yang bersifat multivariat dan kompleks memerlukan pendekatan analisis yang tepat untuk mengidentifikasi pengelompokan yang bermakna. Oleh karena itu, penelitian ini merumuskan masalah yaitu belum diketahuinya metode clustering yang paling optimal antara *K-Means, K-Medians,* DBSCAN, *Mean Shift*, dan *Fuzzy C-Means* dalam mengelompokkan data kesehatan ibu hamil, serta bagaimana karakteristik klinis tiap cluster pada metode terbaik berdasarkan Silhouette Index dan Dunn Index. Adapun tujuan penelitian ini adalah membandingkan performa kelima metode clustering tersebut, menentukan metode dengan hasil cluster terbaik berdasarkan *Silhouette Index*, serta melakukan *Exploratory Data Analysis* (EDA) pada *cluste*r terbaik untuk mengidentifikasi pola dan karakteristik risiko kesehatan maternal secara mendalam.

BAB 2 Metodologi Penelitian

A. Penjelasan Dataset

Penelitian ini menggunakan dataset *Maternal Health Risk Assessment* yang dapat diakses secara resmi melalui laman *Mendeley Data*. Dataset ini memuat informasi klinis dan fisiologis ibu hamil untuk mengevaluasi tingkat risiko kesehatan selama kehamilan. Terdapat 1.205 observasi dengan 11 variabel numerik dan 1 variabel kategorikal, yang diterbitkan pada 1 November 2024, mencakup variabel seperti usia, tekanan darah sistolik dan diastolik, kadar gula darah, suhu tubuh, serta indeks massa tubuh (BMI). Konteks studi difokuskan pada pengamatan risiko medis untuk mencegah komplikasi kehamilan secara dini. Melalui metode *clustering* seperti *K-Means, K-Median, DBSCAN, Mean Shift*, dan *Fuzzy C-Means*, data digunakan untuk mengelompokkan individu ke dalam beberapa *cluster* berdasarkan kemiripan karakteristik, sehingga dapat mengidentifikasi pola kesehatan maternal yang terbentuk dalam data.

B. Variabel Penelitian

Tabel 1 berikut menunjukkan variabel yang digunakan dalam penelitian ini.

Tabel 1. Variabel Penelitian

Simbol	**Nama Variabel**		
X1	Usia	X7	Komplikasi sebelumnya
X2	Tekanan darah sistolik	X8	Diabetes melitus sebelumnya
X3	Tekanan darah diastolik	X9	Diabetes gestasional
X4	Gula darah	X10	Kesehatan mental
X5	Suhu tubuh	X11	Detak jantung
X6	Indeks massa tubuh		

C. *K-means*

K-Means merupakan salah satu metode *clustering* yang paling banyak digunakan dalam analisis data multivariat. Metode ini bekerja dengan cara mempartisi data ke dalam k kelompok berdasarkan kedekatan jarak setiap observasi terhadap titik pusat *cluster* atau yang disebut *centroid* (Oti et al., 2021). Proses K-Means bersifat iteratif, di mana setiap titik data dialokasikan ke cluster dengan centroid terdekat menggunakan ukuran *Euclidean Distance*, kemudian *centroid* diperbarui dengan menghitung rata-rata seluruh anggota *cluster* pada setiap iterasi hingga tidak ada perubahan pengelompokan (Chong, 2021). Secara matematis, tujuan optimasi *K-Means* adalah meminimalkan nilai total *within-cluster sum of squares* (WCSS), yaitu jumlah kuadrat jarak antara setiap titik data dengan centroid clusternya (Wulandari & Yogantara, 2022). Penentuan jumlah cluster optimal dalam *K-Means* dapat dilakukan menggunakan *Elbow Method*, yaitu dengan mengidentifikasi titik di mana penurunan nilai WCSS mulai melandai secara signifikan (Chong, 2021). Meskipun *K-Means* memiliki keunggulan berupa kesederhanaan dan efisiensi komputasi, metode ini memiliki kelemahan berupa sensitivitas terhadap outlier dan ketergantungan pada pemilihan nilai k serta inisialisasi *centroid* awal (Oti et al., 2021).

D. *K-medians*

K-Medians merupakan pengembangan dari metode *K-Means* yang menggunakan median sebagai titik pusat cluster, berbeda dengan *K-Means* yang menggunakan nilai rata-rata atau *mean*. Perbedaan mendasar ini menjadikan K-Medians lebih robust atau tahan terhadap keberadaan *outlier* dalam data, karena median secara statistik deskriptif lebih resisten terhadap nilai ekstrem dibandingkan mean. Selain itu, *K-Medians* menggunakan

Manhattan Distance atau jarak L1 sebagai ukuran kedekatan antar observasi, bukan *Euclidean Distance* seperti pada *K-Means*. *Manhattan Distance* mengukur jarak berdasarkan jumlah selisih absolut pada setiap dimensi variabel. Langkah-langkah algoritma *K-Medians* pada dasarnya sama dengan *K-Means*, yaitu menentukan jumlah *cluster*, menginisialisasi titik pusat secara acak, menghitung jarak setiap observasi ke masing-masing *centroid*, mengalokasikan observasi ke cluster terdekat, memperbarui *centroid* menggunakan median, dan mengulangi proses hingga konvergen. Dalam hal kualitas *clustering*, *K-Median*s terbukti menghasilkan nilai variansi yang lebih kecil dibandingkan K-Means pada beberapa kasus, yang mengindikasikan bahwa pengelompokan yang dihasilkan lebih kompak dan homogen (Famalika & Sihombing, 2021).

E. DBSCAN

Metode DBSCAN merupakan salah satu teknik *clustering* berbasis kepadatan (*density-based*) yang digunakan untuk mengelompokkan data berdasarkan kedekatan jarak antar titik dalam suatu ruang fitur. Konsep dasar DBSCAN adalah membentuk *cluster* dari area dengan kepadatan tinggi (*dense regions*) serta mengidentifikasi titik-titik yang berada di luar area tersebut sebagai *noise* atau *outlier*. Algoritma ini sangat populer karena sederhana untuk diterapkan dan hanya membutuhkan dua parameter input (Bagus et al., 2023). Metode ini menggunakan dua parameter utama, yaitu *epsilon* (ε) dan *MinPts*. *Epsilon* menentukan jarak maksimum antar titik dalam satu *cluster*, sedangkan *minPts* merupakan jumlah minimum titik dalam radius *epsilon* untuk membentuk suatu *cluster* (Bagus et al., 2023). Penentuan nilai epsilon optimal menggunakan metode jarak KNN (*k-nearest neighbors*) atau k-tetangga terdekat (Karmenova et al., 2022). Dalam penelitian ini, DBSCAN diterapkan pada data kesehatan ibu hamil yang telah distandarisasi untuk mengidentifikasi pola pengelompokan berdasarkan kemiripan karakteristik kesehatan.

F. Mean Shift

Mean Shift merupakan algoritma non parametrik (Rizuan et al., 2023). Metode *Mean Shift* adalah salah satu teknik *clustering* berbasis kepadatan yang bekerja dengan cara menggeser (*shifting*) titik data menuju area dengan kepadatan tertinggi (*mode*) dalam ruang fitur. *Mean Shift* tidak memerlukan asumsi awal mengenai jumlah klaster seperti metode *K-Means*, sehingga lebih fleksibel dalam menangkap pola alami dalam data (Musaffak et al., 2025). Algoritma ini beroperasi dengan mengidentifikasi area dengan konsentrasi data yang tinggi, kemudian secara bertahap menggeser setiap titik data menuju rata-rata lokal dari titik-titik di sekitarnya dalam jangkauan tertentu (Luthfia et al., 2023). Selama proses iterasi, *centroid* semakin mendekati daerah yang memiliki kepadatan lebih tinggi hingga mencapai kestabilan, membentuk klaster di sekitar titik-titik dengan distribusi data terbesar.

G. Fuzzy C-means

Fuzzy C-Means (FCM) merupakan metode clustering berbasis logika *fuzzy*, di mana setiap observasi memiliki derajat keanggotaan bernilai 0 hingga 1 pada setiap *cluster*, sehingga tidak dialokasikan secara tegas ke satu *cluster* saja. Prinsip kerjanya adalah meminimalkan fungsi objektif berupa jumlah tertimbang kuadrat jarak setiap observasi terhadap pusat *cluster*, dengan bobot ditentukan oleh derajat keanggotaan dan parameter fuzzifikasi m. Algoritma ini bekerja secara iteratif dengan memperbarui matriks keanggotaan dan pusat cluster hingga perubahan fungsi objektif lebih kecil dari toleransi error yang ditentukan (Sari et al., 2021). Keunggulan FCM dibanding K-Means terletak pada kemampuannya menangani data ambigu di batas antar cluster, menghasilkan pengelompokan yang lebih halus. Jumlah cluster optimal ditentukan menggunakan indeks *Pseudo-F* (Wulandari & Yogantara, 2022).

H. Indeks Pembangunan Manusia

Indeks Pembangunan Manusia (IPM) merupakan indikator komposit yang digunakan untuk mengukur keberhasilan pembangunan kualitas hidup manusia melalui beberapa dimensi dasar, yaitu umur panjang dan hidup sehat, pengetahuan, serta standar hidup layak (Conceição, 2024). Dalam penelitian ini, meskipun analisis difokuskan pada data kesehatan ibu hamil, konsep IPM tetap relevan karena dimensi kesehatan merupakan salah satu komponen utama dalam pembentukan IPM. Dengan demikian, pengelompokan (*clustering*) data maternal health menggunakan metode *K-Means, K-Median, DBSCAN, Mean Shift*, dan *Fuzzy C-Means* dapat memberikan gambaran segmentasi risiko kesehatan yang secara tidak langsung berkaitan dengan kualitas pembangunan manusia, khususnya pada

aspek kesehatan ibu. Hasil *clustering* ini diharapkan dapat mendukung upaya peningkatan kualitas kesehatan maternal yang berkontribusi terhadap peningkatan nilai IPM secara keseluruhan.

BAB 3 Hasil dan Pembahasan

A. Karakteristik Data

Karakteristik faktor risiko kehamilan pada dataset yang digunakan dalam penelitian ini mencakup 11 indikator.

Tabel 2. Karakteristik Faktor Resiko Kehamilan Ibu

Variable	Mean	Median	SD	Min	Max
Age	27,483	25	9,197	10	65
Systolic.BP	116,832	120	18,678	70	200
Diastolic	77,176	80	14,282	40	140
BS	7,5	6,9	3,047	3	19
Body.Temp	98,396	98	1,088	97	103
BMI	23,31	23	3,847	0	37
Previous.Complication	0,175	0	0,38	0	1
Preexisting.Diabetes	0,288	0	0,453	0	1
Gestational.Diabetes	0,118	0	0,323	0	1
Mental.Health	0,334	0	0,472	0	1
Heart.Rate	75,817	76	7,221	58	92

Berdasarkan hasil statistik deskriptif pada tabel 2, rata-rata usia ibu adalah 27, 48 tahun dengan standar deviasi 9,19 tahun, menunjukkan variasi usia signifikan di kalangan populasi ibu Tekanan darah sistolik (rata-rata 116,83 mmHg) dengan nilai maksimum mencapai 200 mmHg, sedangkan tekanan darah diastolik (rata-rata 77,18 mmHg) dengan nilai maksimum 140 mmHg. Nilai maksimum tersebut mengindikasikan adanya beberapa individu dengan tekanan darah yang tinggi, yang mengindikasikan risiko hipertensi dalam kehamilan (Fiana, 2024). Kadar gula darah (BS) memiliki rata-rata 7,5 dengan nilai maksimum mencapai 19. Hal tersebut menunjukkan adanya risiko diabetes gestasional yang cukup signifikan (Aspilayuli, 2023). Suhu tubuh rata-rata sebesar 98,40°F dengan standar deviasi yang relatif kecil (1,09), menunjukkan distribusi yang cukup stabil di sekitar nilai normal fisiologis. Indeks massa tubuh (BMI) memiliki rata-rata 23,31 dengan rentang 0 hingga 37, yang menunjukkan adanya variasi status gizi dari kategori normal hingga obesitas. Detak jantung memiliki rata-rata 75,82 bpm dengan nilai maksimum 92 bpm, masih berada dalam rentang fisiologis normal.

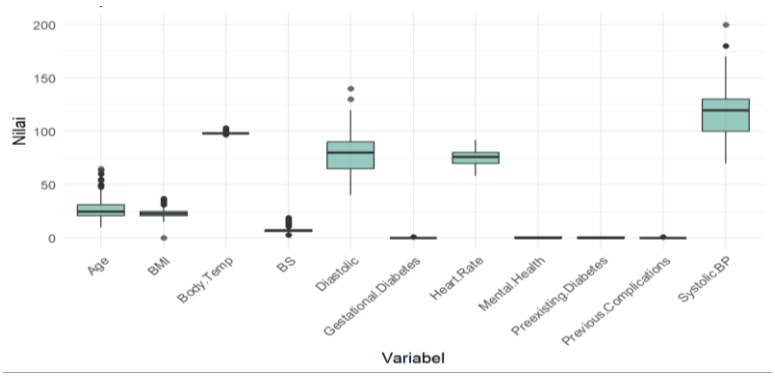

Gambar 1. Distribusi data tiap variabel

Berdasarkan boxplot, terdapat beberapa outlier pada variabel usia, tekanan darah, kadar gula darah, dan detak jantung, namun tidak dihapus karena masih dalam rentang klinis yang wajar dan merepresentasikan kondisi risiko nyata. Selain itu, karena terdapat perbedaan skala antar variabel, dilakukan standarisasi sebelum dilakukan *clustering* agar tidak terjadi dominasi variabel dengan varians besar dan seluruh variabel berkontribusi secara seimbang.

B. Clustering menggunakan *K-Means, K-Median, DBSCAN, Mean Shift*, dan *Fuzzy C-Means*

1. K-Means

   Berdasarkan hasil visualisasi (terlampir pada Lampiran 3), jumlah cluster optimal k=3 ditentukan menggunakan *Elbow Method* dengan memilih titik di mana

penurunan nilai total *within-cluster sum of squares* mulai melandai. Terlihat bahwa ketiga cluster terbentuk dengan pemisahan pada ruang PCA. *Cluster* 3 mendominasi sisi kiri plot dan mengelompokkan ibu hamil dengan profil risiko rendah, di mana tekanan darah, kadar gula darah, dan BMI berada dalam rentang normal. Cluster 1 berada di posisi tengah dan mencerminkan kelompok risiko sedang dengan beberapa indikator klinis yang sedikit meningkat. Sementara itu, *Cluster* 2 terkonsentrasi di sisi kanan plot dengan nilai PC1 tinggi, mengelompokkan ibu hamil berisiko tinggi yang ditandai oleh gula darah, tekanan darah, dan BMI yang lebih tinggi dibandingkan kelompok lainnya.

2. K-Medians
   Berdasarkan hasil visualisasi (terlampir pada Lampiran 3), jumlah *cluster* optimal k=4 ditentukan menggunakan *Elbow Method* berbasis nilai total *sum of absolute deviations* (SAD) dengan jarak *Manhattan*, di mana titik siku terbaik diperoleh pada k=4. Terlihat bahwa keempat cluster membentuk pola pemisahan yang lebih rinci dibandingkan K-Means. *Cluster* 1 terletak di sisi kanan plot dan mengelompokkan ibu hamil berisiko tinggi dengan nilai tekanan darah dan gula darah tertinggi. *Cluster* 3 berada di posisi peralihan dan mencerminkan kelompok risiko sedang. *Cluster* 2 dan *Cluster* 4 sama-sama terkonsentrasi di sisi kiri plot, namun memisahkan dua sub-kelompok risiko rendah yang memiliki perbedaan halus menunjukkan bahwa *K-Medians* lebih sensitif dalam mendeteksi variasi internal data.

3. DBSCAN
   Berdasarkan hasil visualisasi (terlampir pada Lampiran 3), *clustering* DBSCAN dengan parameter terbaik yaitu *epsilon* (ε) sebesar 0,75 dan *MinPts* sebesar 5, terlihat bahwa sebagian besar data diklasifikasikan sebagai *noise* (*cluster* 0) yang ditunjukkan oleh sebaran titik berwarna merah yang mendominasi hampir seluruh ruang komponen utama. Hal ini menunjukkan bahwa mayoritas data tidak berada pada area dengan kepadatan yang cukup tinggi untuk membentuk cluster menurut DBSCAN. Sementara itu, hanya terdapat sebagian kecil data yang berhasil membentuk *cluster* 1 (hijau) yang terkonsentrasi pada area dengan kepadatan relatif lebih tinggi di sisi kiri plot, serta *cluster* 2 (biru) yang jumlahnya sangat terbatas dan berada di sekitar pusat kepadatan *cluster* utama. Pola ini mengindikasikan bahwa struktur data cenderung tidak memiliki pemisahan berbasis densitas yang kuat, sehingga DBSCAN kesulitan dalam mengidentifikasi kelompok yang jelas. Meskipun parameter yang digunakan telah melalui proses *tuning*, tingginya jumlah *noise* mengindikasikan bahwa karakteristik data kurang sesuai dengan pendekatan berbasis densitas.

4. Mean Shift
   Sebelum proses clustering dilakukan terlebih dahulu penentuan parameter *bandwidth* yang optimal, di mana diperoleh nilai *bandwidth* sebesar 1,5. Pemilihan *bandwidth* ini bertujuan untuk menentukan tingkat kepadatan data yang digunakan dalam pembentukan *cluster*, sehingga hasil pengelompokan menjadi lebih representatif terhadap struktur data. Dengan menggunakan *bandwidth* tersebut, terlihat pada Lampiran 3 hasil *clustering* menunjukkan terbentuknya dua kelompok utama, yaitu satu *cluster* besar yang mencakup mayoritas data dan tersebar luas pada ruang komponen utama, serta satu cluster lainnya yang lebih kecil. Hal ini menunjukkan bahwa *Mean Shift* mampu mengidentifikasi pusat kepadatan data (*mode*) secara adaptif tanpa perlu menentukan jumlah *cluster* di awal, di mana *bandwidth* berperan penting dalam mengontrol sensitivitas algoritma terhadap variasi kepadatan data.

5. Fuzzy C-means
   Berdasarkan hasil visualisasi, jumlah cluster optimal c=2 ditentukan berdasarkan nilai *Pseudo-F* tertinggi dalam rentang c=2 hingga c=10, di mana c=2 menghasilkan rasio variansi antar kelompok terhadap variansi dalam kelompok yang paling optimal. Terlihat bahwa kedua cluster membentuk pemisahan yang cukup jelas berdasarkan sumbu PC1. *Cluster* 2 mendominasi sisi kiri plot dan mencakup ibu hamil dengan profil risiko rendah hingga sedang, dengan indikator klinis yang relatif

terkendali. *Cluster* 1 terkonsentrasi di sisi kanan. Karena pendekatan fuzzy, batas antar *cluster* tidak bersifat tegas sehingga observasi di zona transisi memiliki derajat keanggotaan di kedua *cluster* sekaligus, mencerminkan kondisi klinis yang ambigu dan memerlukan perhatian lebih lanjut.

C. Evaluasi

Tabel 3. Distribusi jumlah cluster tiap metode

Metode *Clustering*	***Silhouette***
Kmeans	0.430
Kmedians	0.310
DBSCAN	0.242
MeanShift	0.100
Fuzzy	**0,459**

Nilai *Silhouette* menunjukkan seberapa baik suatu data berada dalam *cluster*-nya dibandingkan *cluster* lain. Semakin tinggi nilainya, maka kualitas clustering semakin baik. Berdasarkan hasil yang diperoleh, *Fuzzy C-means* memiliki performa terbaik dengan nilai *Silhouette* 0,459 yang menunjukkan bahwa *cluster* yang terbentuk cukup baik. Metode *K-means* dan *K-median* juga memiliki nilai *Silhouette* yang cukup tinggi (0,430 dan 0,310). Sementara itu, DBSCAN dan *meanshift* memiliki nilai *Silhouette* yang paling Rendah diantara etode lainnya (0,100 dan 0,242).

D. EDA Metode Fuzzy C-Means

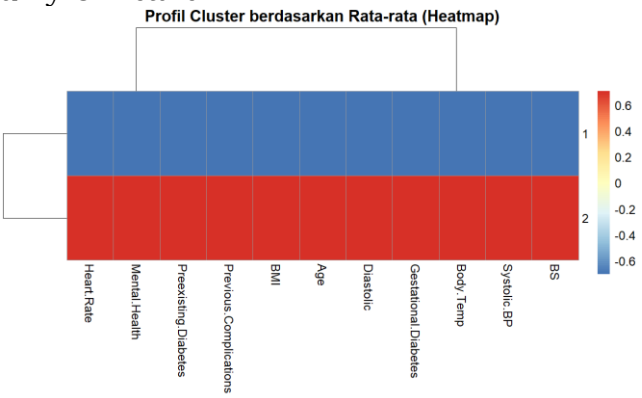

Gambar 2. Profil tiap *Cluster* Berdasar *mean* menggunakan *Fuzzy C-means*

Berdasarkan hasil analisis karakteristik tiap klaster menggunakan metode *Fuzzy C-Means* dengan jumlah klaster optimal sebanyak 2, terlihat bahwa klaster 1 memiliki nilai rata-rata (mean) yang cenderung lebih tinggi pada beberapa variabel utama seperti *BMI, kadar gula darah (BS), serta riwayat komplikasi*, yang menunjukkan bahwa kelompok ini didominasi oleh individu dengan kondisi kesehatan yang relatif lebih berisiko. Selain itu, nilai standar deviasi pada klaster ini juga cukup besar, yang mengindikasikan adanya variasi karakteristik antar individu dalam klaster tersebut, terlampir pada Lampiran 1.

Sementara itu, klaster 2 menunjukkan nilai rata-rata yang relatif lebih rendah pada sebagian besar variabel, yang mengindikasikan bahwa kelompok ini cenderung memiliki kondisi kesehatan yang lebih baik atau risiko yang lebih rendah. Karakteristik dalam klaster ini juga cenderung lebih homogen, ditunjukkan oleh nilai standar deviasi yang lebih kecil dibandingkan klaster 1.

Gambar 3. Distribusi Age tiap *cluster* metode *Fuzzy C-Means*

Distribusi usia pada masing-masing *cluster* menunjukkan perbedaan karakteristik yang cukup jelas. *Cluster 1* memiliki distribusi yang terkonsentrasi pada nilai usia yang

lebih rendah, dengan puncak kepadatan berada pada rentang nilai di bawah rata-rata (karena data telah distandarisasi), serta sebaran yang relatif sempit yang menandakan bahwa anggota cluster ini cenderung homogen dan didominasi oleh individu dengan usia lebih muda. Sebaliknya, *Cluster 2* menunjukkan distribusi yang bergeser ke arah usia yang lebih tinggi dengan sebaran yang lebih luas, mengindikasikan variasi usia yang lebih besar di dalam *cluster* tersebut. Selain itu, adanya ekor distribusi pada nilai yang lebih tinggi menunjukkan keberadaan individu dengan usia relatif lebih tua.

BAB 4 Kesimpulan dan Saran

A. Kesimpulan

Berdasarkan hasil analisis yang telah dilakukan, dapat disimpulkan bahwa proses *clustering* pada data *maternal health* yang diawali dengan *scaling* dan reduksi dimensi menggunakan PCA mampu meningkatkan kualitas pengelompokan data. Hasil evaluasi menggunakan *Silhouette Index* menunjukkan bahwa metode *Fuzzy C-Means* dengan jumlah klaster optimal sebanyak 2 memberikan performa terbaik dengan nilai sebesar 0,459, yang mengindikasikan bahwa struktur klaster yang terbentuk cukup baik dan memiliki pemisahan yang jelas.

Analisis eksplorasi data (EDA) pada metode terbaik, yaitu *Fuzzy C-Means*, diperoleh bahwa data terbagi menjadi dua klaster utama, di mana klaster 1 merepresentasikan kelompok dengan tingkat risiko kesehatan yang lebih tinggi, ditandai dengan nilai rata-rata variabel yang lebih besar, sedangkan klaster 2 merepresentasikan kelompok dengan risiko kesehatan yang lebih rendah dan karakteristik yang lebih homogen. Dengan demikian, metode *Fuzzy C-Means* mampu memberikan segmentasi yang jelas dan informatif dalam mengidentifikasi tingkat risiko kesehatan ibu hamil.

B. Saran

Pertama, penelitian selanjutnya dapat mempertimbangkan penggunaan metode *clustering* lain yang lebih kompleks atau berbasis model, seperti *Gaussian Mixture Model* (GMM), untuk membandingkan hasil yang diperoleh. Kedua, penambahan variabel yang lebih beragam, seperti faktor sosial ekonomi atau riwayat kesehatan yang lebih detail, dapat meningkatkan kualitas analisis dan memberikan insight yang lebih komprehensif. Selain itu, penelitian juga dapat dikembangkan dengan menggunakan teknik validasi *cluster* tambahan seperti *Davies-Bouldin Index* atau *Calinski-Harabasz Index* untuk memperkuat hasil evaluasi.

Daftar Pustaka

A. Luthfia, H. Yahman, J. Sianturi, F. Zaharani, U. N. Medan, and M. S. (2024). Clustering, "PENERAPAN ALGORITMA MEAN SHIFT CLUSTERING UNTUK SEGMENTASI PELANGGAN WHOLESALE BERDASARKAN POLA," vol. 10, no. 11, pp. 44–55.

Bagus, I., Arafat, F., Hariyadi, M. A., Santoso, I. B., Crysdian, C., Islam, U., Maulana, N., Ibrahim, M., & Korespondensi, P. (2023). *CLUSTERING GEMPABUMI DI WILAYAH REGIONAL VII EARTHQUAKE CLUSTERING IN REGIONAL VII USING DBSCAN APPROACH*. *10*(4). https://doi.org/10.25126/jtiik.2023106918.

Cariou, C., Le Moan, S., & Chehdi, K. (2022). A novel mean-shift algorithm for data clustering. *IEEE Access*, *10*, 14575–14585. https://doi.org/10.1109/ACCESS.2022.3147951

Chen, X., Park, C., Gao, X., & Kim, B. (2023). Robust model design by comparative evaluation of clustering algorithms. *IEEE Access*, *11*. https://doi.org/10.1109/ACCESS.2023.3306023

Chicco, D., Oneto, L., & Cangelosi, D. (2025). DBSCAN and DBCV application to open medical records heterogeneous data for identifying clinically significant clusters of patients with neuroblastoma. *BioData Mining*. https://doi.org/10.1186/s13040-025-00455-8

Chong, B. (2021). K-means clustering algorithm: A brief review. *Academic Journal of Computing & Information Science*, *4*(5), 37–40. https://doi.org/10.25236/AJCIS.2021.040506

Conceição, Pedro. (2024). Human development report 2023/2024: breaking the gridlock: reimagining cooperation in a polarized world. United Nations Development Programme.

Famalika, A., & Sihombing, P. R. (2021). Implementation of K-Means and K-Medians clustering in several countries based on Global Innovation Index (GII) 2018. *Advance*

Sustainable Science, Engineering and Technology (ASSET), *3*(1), 0210107-01–0210107-09. https://doi.org/10.26877/asset.v3i1.8461

Ishak, R. (2024). *Optimasi K-Means pada Clustering Penyakit Ibu Hamil Menggunakan Random Forest Optimization of K-Means in Disease Clustering of Pregnant Women Using Random Forest*. *7*, 41–47.

KARMENOVA, M., TLEBALDINOVA, A., KRAK, I., DENISSOVA, N., POPOVA, G., ZHANTASSOVA, Z., PONKINA, E., & GYÖRÖK, G.,2022. An Approach for Clustering of Seismic Events using Unsupervised Machine Learning. Acta Polytechnica Hungarica,m 19(5), 7–22. https://doi.org/10.12700/APH.19.5.2022.5.1

Maulindar, J., & Yudha, E. P. (2023). Pengembangan klastering untuk penanganan ibu hamil menggunakan K-Means. *Prosiding Seminar Nasional Teknologi Informasi dan Bisnis (SENATIB) 2023*, 703. Universitas Duta Bangsa Surakarta. https://www.ojs.udb.ac.id/Senatib/article/view/3265/2667

Max Roser and Hannah Ritchie. (2024) Maternal Mortality—Our World in Data. Available from: https://ourworldindata.org/maternal-mortality

Musaffak, A. L., Hindrayani, K. M., Idhom, M., Data, S., Anyar, G., Shift, M., & Score, S. (2025). *PENERAPAN METODE MEAN SHIFT CLUSTERING UNTUK MENGELOMPOKKAN*. *9*(3), 4790–4797.

Oti, E. U., Olusola, M. O., Eze, F. C., & Enogwe, S. U. (2021). Comprehensive review of K-Means clustering algorithms. *International Journal of Advances in Scientific Research and Engineering (IJASRE)*, *7*(8). https://doi.org/10.31695/IJASRE.2021.34050

R. Rizuan, E. Haerani, J. Jasril, and L. Oktavia. (2023). "Penerapan Algoritma Mean-Shift Pada Clustering Penerimaan Bantuan Pangan Non Tunai," J. Comput. Syst. Informatics, vol. 4, no. 4, pp. 1019–1027, doi: 10.47065/josyc.v4i4.3876.

Sari, I. P., Al-Khowarizmi, & Batubara, I. H. (2021). Cluster analysis using K-Means algorithm and Fuzzy C Means clustering for grouping students' abilities in online learning process. *Journal of Computer Science, Information Technology and Telecommunication Engineering (JCoSITTE)*, *2*(1), 139–144. https://doi.org/10.30596/jcositte.v2i1.6504

Setiawan, K. E., Kurniawan, A., Chowanda, A., & Suhartono, D. (2023). Clustering models for hospitals in Jakarta using fuzzy c-means and k-means. *Procedia Computer Science*, *216*, 1–8. https://doi.org/10.1016/j.procs.2022.12.146

Shutaywi, M., & Kachouie, N. N. (2021). Silhouette analysis for performance evaluation in machine learning with applications to clustering. *Entropy*, *23*(6), 759. https://doi.org/10.3390/e23060759

Tarmizi, S. N. (2023). *https://mediakom.kemkes.go.id/*.

Wulandari, L., & Yogantara, B. O. (2022). Algorithm analysis of K-Means and Fuzzy C-Means for clustering countries based on economy and health. *Faktor Exacta*, *15*(2), 109–116. https://doi.org/10.30998/faktorexacta.v15i2.12106

Lampiran

Lampiran 1. Tabel Karakteristik Tiap *Cluster* Menggunakan Metode K-Median

Variable	Statistik	Cluster 1	Cluster 2
Age	mean	-0,232677	0,43329867
Age	sd	0,87937252	1,06572441
BMI	mean	-0,4291055	0,79909434
BMI	sd	0,63894058	1,05914914
BS	mean	-0,4695821	0,87447113
BS	sd	0,44369293	1,14957508
Body.Temp	mean	-0,0906469	0,16880563
Body.Temp	sd	0,88823484	1,16271938
Diastolic	mean	-0,2907778	0,54149594
Diastolic	sd	0,8263139	1,06864235
Gestational.Diabetes	mean	-0,2783434	0,51834015
Gestational.Diabetes	sd	0,51232539	1,40121294
Heart.Rate	mean	-0,3703705	0,68971613
Heart.Rate	sd	0,68067396	1,12694791
Mental.Health	mean	-0,4869763	0,90686314

Mental.Health	sd	0,64878923	0,9027217
Preexisting.Diabetes	mean	-0,4611115	0,85869704
Preexisting.Diabetes	sd	0,59610658	1,03353354
Previous.Complications	mean	-0,4269932	0,79516078
Previous.Complications	sd	0,29532752	1,31527336
Systolic.BP	mean	-0,2688988	0,5007521
Systolic.BP	sd	0,80683806	1,12548557

Lampiran 2. Link Rpubs
https://rpubs.com/sofiadwik/1420940

Lampiran 3. Visualisasi *Clustering* tiap Metode

1. Metode K-means

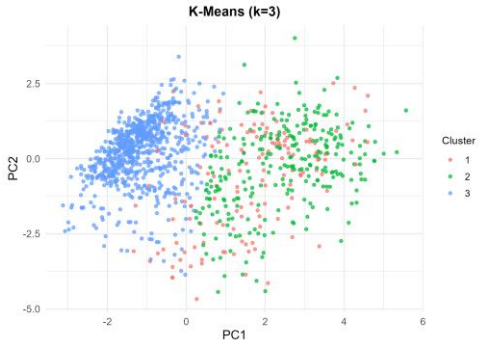

2. Metode K-Medians

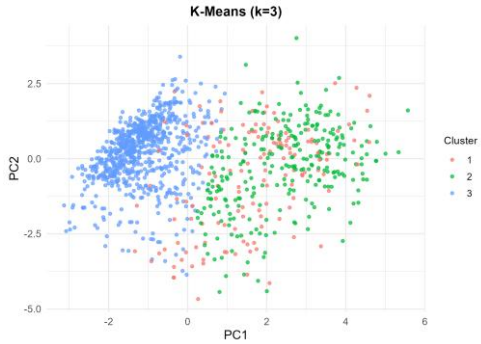

3. Metode DBSCAN

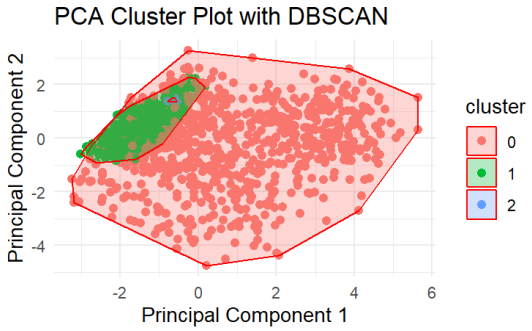

4. Metode Mean Shift

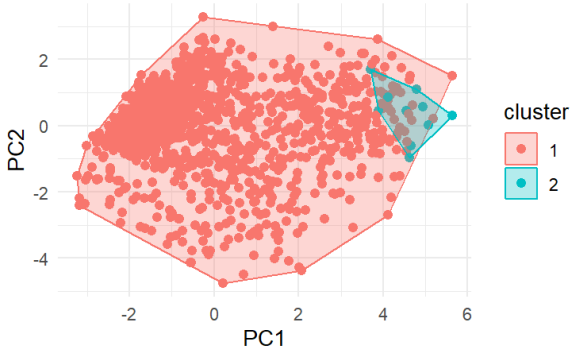
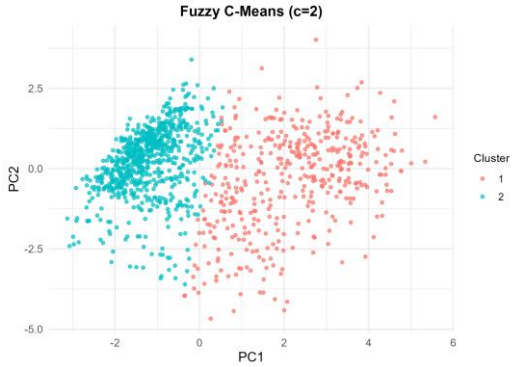
5. Metode Fuzzy C-Means